Spike del VLM: evaluación de Gemini para analizar menús de restaurante

GluMee · Proyecto de titulación, CETI Colomos · Gabriela Jireh Arambula Cruz y Ana Sofía Guerrero Ruiz Velasco · 30 de octubre de 2026

Ficha	
Estado	Cerrado. Configuración congelada (registro en `docs/decisiones/0002-vlm-congelado.md`)
Relación con el Charter	Objetivos específicos 3, 4 y 5; riesgo «Baja precisión del VLM»; criterio de éxito del 80 %
Modelo y prompt finales	`gemini-3.8-flash` · prompt v3 (`spike/spike_menuV3.py`)

1. Resumen

Antes de construir el módulo de análisis de menús se probó si un modelo de lenguaje multimodal (Gemini) puede leer fotografías reales de menús, separar las entradas, clasificarlas y calificar su compatibilidad con los criterios alimentarios de un perfil. Se evaluaron **15 menús de restaurantes de Guadalajara** en tres iteraciones del prompt, y la medición final se hizo con el prompt y el modelo congelados.

Medida (medición final, 15 menús)	Resultado
Entradas de menú verificadas	812
Precisión (de lo detectado, cuánto existe)	**99.9 %** (810 de 811; IC 95 % 99.3 a 100.0 %)
Cobertura (de lo que existe, cuánto se detectó)	**99.8 %** (810 de 812; IC 95 % 99.1 a 99.9 %)
Clasificación por tipo (platillo, bebida, postre)	100 % de 810 entradas revisadas
Compatibilidad juzgada razonable	**93.7 %** (148 de 158 entradas; IC 95 % 88.7 a 96.5 %)
Menús no usados para ajustar el prompt (10 menús, 377 entradas)	0 errores de lectura

> ***Conclusión.*** *La lectura de menús con un VLM es viable para el producto (el criterio de éxito del Charter, 80 %, se supera con amplio margen). La parte más frágil no es la lectura, sino la* ***calificación de compatibilidad****, que a veces afirma cosas que el menú no dice o se sale de los criterios del perfil (sección 6.5). La cobertura media de la ronda 1 (67 %) mejoró sobre todo por* ***cambios en el prompt****: en los menús comparados con el mismo modelo la mejora fue de instrucciones. No se hizo una comparación controlada entre modelos.*

2. Objetivo y alcance

Pregunta: ¿Puede un VLM leer una foto de un menú y devolver, en una sola llamada, las entradas del menú, su tipo y una calificación de compatibilidad con el perfil, con un error suficientemente bajo para usarse en la app?

Dentro del spike: Lectura del texto del menú desde imágen, expansión de variantes, clasificación (platillo, bebida, postre), calificación de compatibilidad con un perfil de prueba, y medición de precisión y cobertura contra revisión humana.

Fuera del spike: lectura de menús por código QR, reconocimiento visual de comida, pruebas con usuarios reales, varios perfiles de usuario, y la integración con la app y el backend.

3. Configuración final (congelada)

Elemento	Valor
Modelo	`gemini-3.8-flash` (API de Google AI, nivel gratuito)
Prompt	Variable `PROMPT` de `spike/spike_menuV3.py` (copia en el Anexo A)
Temperatura	0.2
Tokens máximos de salida	32 000 (`MAX_SALIDA`)
Formato de salida	JSON (`response_mime_type = application/json`)
Perfil de prueba	Diabetes tipo 2; criterios: bajo en carbohidratos refinados, evitar bebidas azucaradas, preferir proteína magra y verduras, limitar frituras
Reintentos	Hasta 4 reintentos ante errores 503 y 429 por minuto; pausa de 13 s entre fotos
Regla de congelación	El prompt no se modifica hasta terminar la medición de los 15 menús

4. Metodología

4.1 Conjunto de menús

Menú	Tipo de imagen	Modelo en ronda 1
1 Jardín Cafeto	Captura de PDF	3.8
2 Cafeto Vinos	Captura de PDF	3.8
3 Cafeto Comida	Captura de PDF	3.8
4 Rayo Bebidas	Captura de PDF	3.8

Menú	Tipo de imagen	Modelo en ronda 1
5 Rayo Comida	Captura de PDF	3.8
6 Sushi	Foto de cerca	3.6
7 Hamburguesas	Foto de baja calidad	3.6
8 Boneless y alitas	Foto de baja calidad	3.6
9 Bebidas	Foto desde ángulo inferior, no central	3.8
10 Comida (fonda)	Foto de cerca, no centrada	3.8
11 Carnes, sopas y postres	Foto centrada	3.8
12 Repetido del 10	Foto no centrada, de derecha a izquierda	3.8
13 Postres	Foto de baja calidad, poca luz, mal ángulo	3.6
14 Comida italiana	Foto de muy baja resolución	3.8
15 Piggy limón	Foto de cerca, buena luz	3.8

Los menús 10 y 12 son **el mismo restaurante fotografiado dos veces**, a propósito, para medir consistencia entre fotos. Las fotografías de los menús **no se versionan** en el repositorio.

4.2 Qué cuenta como «entrada» y cómo se revisó

1. Se cuenta **una entrada por variante impresa** en el menú (por ejemplo, «Latte - chai» y «Latte - matcha»).
2. Los **extras y modificadores** (complementos con costo, tamaños, tipos de leche como cambio de otra bebida, toppings) no cuentan. Si el modelo los incluye, es un error.
3. Un error menor de ortografía en el nombre se mantiene como correcto y se anota como `errata`.
4. Los títulos de sección no son entradas.
5. Lo que está cortado o ilegible a simple vista en la foto no cuenta como omisión.

Procedimiento. Para cada menú el script genera una hoja CSV (`evaluar.py`) con una fila por entrada detectada. Cada fila se compara con la foto y se marca `ok` (existe), `x` (no existe o es un extra) o se agrega una fila `falto` por cada entrada real no detectada. El total de entradas reales se obtiene como `ok + falto`, y no se cuenta aparte.

Métricas.

- **Precisión** = `ok / (ok + x)`: de lo que el modelo dijo, cuánto es cierto.
- **Cobertura** (*recall*) = `ok / (ok + falto)`: de lo que existe en el menú, cuánto encontró el modelo.
- Se reportan dos agregados: el **promedio por menú** y la **suma de entradas**.
- **Tipo correcto** y **compatibilidad razonable** se juzgan por fila (`s` o `n`). La compatibilidad se revisó en una muestra de unas 12 entradas por menú, repartidas entre «alta», «media» y «baja», incluyendo algunas cercanas a los umbrales.

Revisoras. La lectura y el tipo los verificó Gabriela Jireh Arambula Cruz junto con Pamela Irais Montoya Don, estudiante de medicina, fila por fila. La compatibilidad la juzgó Pamela Irais Montoya Don. Ella no es profesional de la salud titulada, por lo que su juicio es una validación académica, no clínica.

4.3 Protocolo de iteración

El prompt se ajustó con un conjunto de desarrollo (menús 1, 6, 8 y 14, y el 3 por su problema de truncamiento) y se midió también en menús que no intervinieron en los ajustes (2, 4, 5, 7, 9, 10, 11, 12, 13 y 15). Al terminar los ajustes se **congeló** la configuración y se midieron los 15 menús con ella. Por eso la sección 6.3 reporta por separado ambos grupos.

5. Evolución del spike

5.1 Ronda 1: prompt v1 (15/10/2026)

Prompt básico: extraer platillos y calificar compatibilidad (alta, media, baja), con `confianza`. Los menús 6, 7, 8 y 13 se procesaron con `gemini-3.6-flash` y el resto con `gemini-3.8-flash`, porque la cuota diaria del segundo se agotó.

Menú	Reales	Correctos	Erróneos	Cobertura	Nota
1 Jardín Cafeto	89	14	0	15.7 %	Agrupó variantes (chilaquiles, molletes, omelettes, hotcakes, jugos)
2 Cafeto Vinos	55	33	0	60.0 %	Detectó la mayor parte de las bebidas
3 Cafeto Comida	132	31	0	23.5 %	Agrupó por categorías (pastas, bebidas, cócteles)
4 Rayo Bebidas	45	39	0	86.7 %	Faltaron varias entradas
5 Rayo Comida	15	15	0	100.0 %	—
6 Sushi	42	10	0	23.8 %	Agrupó los rellenos de cada rollo
7 Hamburguesas	14	14	0	100.0 %	—
8 Boneless y alitas	24	5	0	20.8 %	Agrupó por salsas
9 Bebidas	35	22	0	62.9 %	Agrupó cervezas de una categoría
10 Comida (fonda)	28	28	0	100.0 %	—
11 Carnes, sopas y postres	27	27	0	100.0 %	—

Menú	Reales	Correctos	Erróneos	Cobertura	Nota
12 Repetido del 10	28	28	0	100.0 %	—
13 Postres	27	23	0	85.2 %	Faltó la sección de vinos (nombre en columna, poca luz)
14 Comida italiana	55	15	0	27.3 %	Solo 15 de 55 (atribuido entonces a imagen borrosa; ver 5.2)
15 Piggy limón	33	33	2	100.0 %	Incluyó 2 extras como si fueran platillos

Global: promedio por menú, cobertura **67.1 %**; suma de entradas, **51.9 %** (337 de 649); precisión 99.4 %.

> ***Corrección de las hojas originales.*** *En* `RESULTADOS.md` *el valor llamado «precisión» es en realidad la* ***cobertura****. Además, el Menú 9 figuraba con 20 %, pero con 22 de 35 es 62.9 %, y el Menú 15 figuraba con 35 correctos sobre 33 reales: son 33 correctos y 2 extras erróneos. Esta tabla ya trae esos valores corregidos.*

Hallazgos de la ronda 1: El modelo casi no inventa (2 errores en 339 entradas detectadas), pero **agrupa variantes** en una sola entrada (chilaquiles, rellenos de sushi, salsas, cervezas) y por eso baja la cobertura. En la comparación de los menús 10 y 12 (mismo restaurante), 26 de 28 calificaciones coincidieron (93 %), y las 2 diferencias fueron entre niveles contiguos.

5.2 Ronda 2: prompt v2 (19/10 y 28/10/2026)

Cambios al prompt: expandir variantes en una entrada cada una, agregar el campo `tipo` (platillo, bebida, postre), excluir extras y modificadores, y añadir `secciones_no_leidas` para que el modelo avise cuando no puede leer una parte. Se aplicó primero a los menús 1, 6, 8 y 14, y después a los menús 2 y 9.

Menú	Detectados en ronda 1	Detectados en ronda 2
1	14	117
6	10	47
8	5	24
14	15	57

Evaluación de la ronda 2 (28/10/2026):

Menú	Reales	Detectados	OK	X	Faltantes	Modelo
1	117	117	117	0	0	3.8
14	57	57	57	0	0	3.8
6	47	47	47	0	0	3.6
8	24	24	24	0	0	3.6
2	54	54	54	0	0	3.8
9	55	55	55	0	0	3.8

Salvedad: el Menú 1 se registró entonces con 100 %, pero varias líneas de chilaquiles seguían agrupadas y no se contaron como faltantes. Esa medición quedó superada por la medición final con el prompt v3.

Hallazgo corregido sobre el Menú 14. En la ronda 1 se atribuyó su baja cobertura (15 de 55) a una imagen borrosa. Con el **mismo modelo y la misma foto**, el prompt v2 detectó 57 entradas, así que la causa era el prompt (el modelo se detenía antes de terminar), no la calidad de imagen. Además, el modelo calificó esa foto como `calidad_imagen: «buena»` aunque tenía baja resolución: **su autoevaluación de calidad no es confiable.**

5.3 Prompt v3 y congelación (30/10/2026)

Problemas de la v2 que motivaron la v3:

Problema observado	Cambio en la v3
Seguían agrupadas líneas con opciones (chilaquiles, jugos, smoothies)	Regla de expansión con ejemplo y una excepción para productos que el cliente arma con ingredientes a elegir
El Menú 3 (157 entradas) se cortó a la mitad: el JSON llegó incompleto	`MAX_SALIDA` de 16 000 a 32 000 tokens; salida más corta (se quitaron `confianza` e `ingredientes_probables`; `razon` de máximo 15 palabras)
`confianza` siempre entre 0.85 y 0.98: no discriminaba	Se reemplazó por `puntaje` de 0 a 100
Casi todas las entradas de un menú quedaban en «media» (sushi: 41 de 47) y no había cómo ordenarlas	`puntaje` con instrucción de usar todo el rango; el prompt define las categorías sobre el puntaje (alta ≥ 70, media 40 a 69, baja < 40)
Razones que daban por hecho algo no escrito en el menú	Prefijo obligatorio «Se supone:» cuando la razón dependa de algo no impreso

Piloto de la v3 con los menús 3, 1 y 6: el Menú 3 terminó completo (157 entradas), los chilaquiles del Menú 1 quedaron en 7 entradas separadas y el rango de puntaje del Menú 6 fue de 35 a 75. Con eso se congeló la configuración y se corrieron los 15 menús.

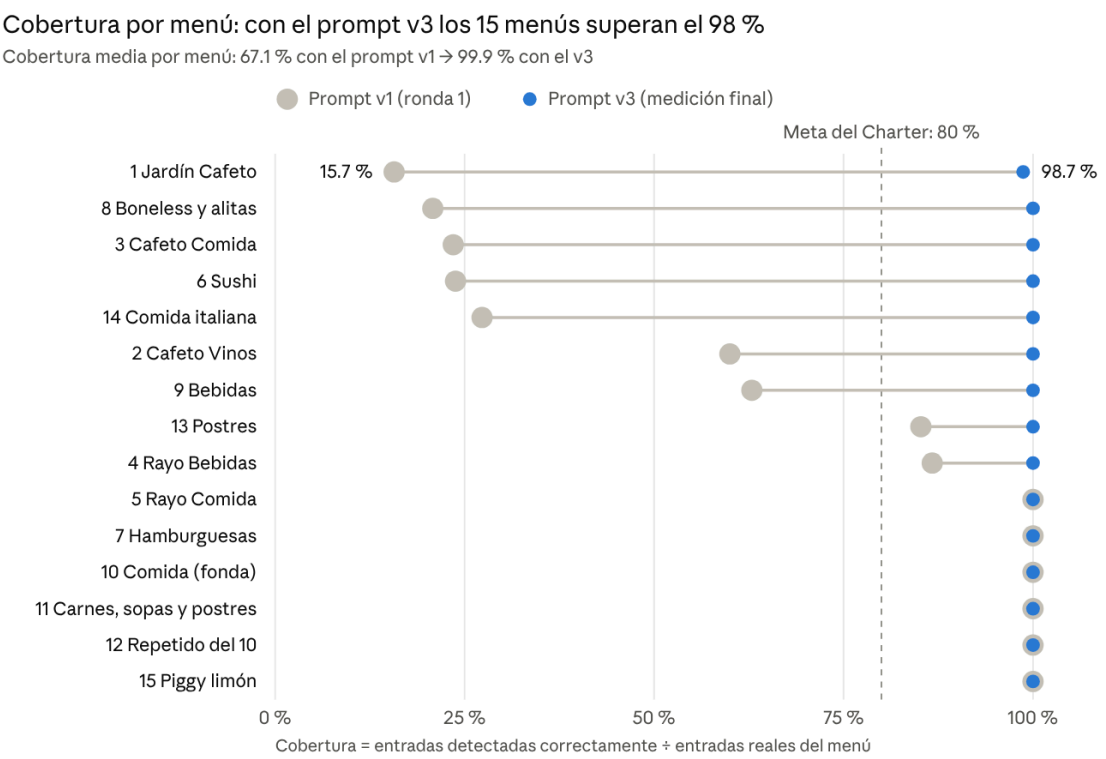
6. Resultados finales (prompt v3, `gemini-3.8-flash`)

6.1 Por menú

Menú	Reales	Detectados	OK	X	Faltantes	Precisión	Cobertura
Menu1	150	149	148	1	2	99.3 %	98.7 %
Menu2	54	54	54	0	0	100.0 %	100.0 %
Menu3	157	157	157	0	0	100.0 %	100.0 %
Menu4	49	49	49	0	0	100.0 %	100.0 %
Menu5	17	17	17	0	0	100.0 %	100.0 %
Menu6	47	47	47	0	0	100.0 %	100.0 %
Menu7	14	14	14	0	0	100.0 %	100.0 %
Menu8	24	24	24	0	0	100.0 %	100.0 %
Menu9	58	58	58	0	0	100.0 %	100.0 %
Menu10	47	47	47	0	0	100.0 %	100.0 %
Menu11	29	29	29	0	0	100.0 %	100.0 %
Menu12	47	47	47	0	0	100.0 %	100.0 %
Menu13	29	29	29	0	0	100.0 %	100.0 %
Menu14	57	57	57	0	0	100.0 %	100.0 %
Menu15	33	33	33	0	0	100.0 %	100.0 %

6.2 Global

	Precisión	Cobertura
Promedio por menú	100.0 %	99.9 %
Suma de entradas (810 OK, 1 X, 2 faltantes)	99.9 %	99.8 %



Mediciones del spike: ronda 1 (15/10/2026) y medición final (30/10/2026), 15 menús

Los seis menús que ya estaban en 100 % en la ronda 1 (5, 7, 10, 11, 12 y 15) no cambiaron. La mejora se concentró en los menús donde el modelo agrupaba variantes (1, 3, 6, 8 y 9) y en los que habían omitido secciones o entradas (2, 4, 13 y 14).

Errores de lectura anotados como errata: 3. Los intervalos son de Wilson al 95 % y son **orientativos**: las entradas de un mismo menú no son independientes.

6.3 Menús de desarrollo y menús no usados para ajustar

Grupo	Menús	Entradas	Errores
Usados para ajustar el prompt	1, 3, 6, 8, 14	435	3 (todos en el Menú 1)
No usados para ajustar	2, 4, 5, 7, 9, 10, 11, 12, 13, 15	377 (330 sin contar el menú 12, repetido)	0

Con 0 errores en 377 entradas, la cota superior del error es de aproximadamente 0.8 % (regla de tres, 95 %), con la misma salvedad de no independencia.

6.4 Errores registrados

Menú	Tipo	Detalle
Menu1	Entrada de más (x)	«Frizana - damasco»: el modelo separó en dos el sabor compuesto «clementina damasco»
Menu1	Faltante	Jugo de betabel y naranja
Menu1	Faltante	Cerveza Victoria
Menu1	Errata	«Frizana - clementina» (nombre incompleto)
Menu1	Errata	«Cerveza - Modelo Especial»: el menú dice solo «Modelo»

6.5 Compatibilidad

De **158 entradas** revisadas, **148** se juzgaron razonables (**93.7 %**; IC 95 % orientativo 88.7 a 96.5 %). Las 158 no son una muestra aleatoria: se eligieron repartidas entre alta, media y baja, con casos cercanos a los umbrales. Las 10 discrepancias:

Menú y entrada	Modelo	Razón del modelo	Patrón observado	Validación
Menu10: CHILES RELLENOS	media 58	El chile y ensalada aportan fibra; incluye arroz y frijoles.	Preparación posiblemente ignorada	El chile es capeado por lo que contiene fritura y carbohidrato refinado.
Menu15: LATTE	alta 70	Café con leche, aporta carbohidratos lácteos moderados sin azúcar extra.	Afirma «sin azúcar extra» sin «Se supone:»; puntaje en el umbral (70)	Es la bebida que más leche utiliza, pudiendo subir la glucosa en personas delicadas.
Menu2: Bombay (50 ml)	media 60	Ginebra seca sin carbohidratos.	Alcohol no está en el perfil	Mínima descripción, excluyendo que además el alcohol frena la oxidación de grasas.
Menu2: Agavero (50 ml)	baja 18	Licor de tequila endulzado con miel de agave.	Afirma el endulzante sin «Se supone:»; alcohol no está en el perfil	Se metaboliza como azúcar libre.

Menú y entrada	Modelo	Razón del modelo	Patrón observado	Validación
Menu3: Portobello relleno	alta 88	Hongo abundante en fibra y muy bajo en carbohidratos.	Relleno posiblemente ignorado	Depende del relleno.
Menu3: Molletes - Toluca	media 42	Pan blanco con chorizo alto en grasas saturadas.	Usa grasa, que no es criterio del perfil; puntaje cerca del umbral (40)	El chorizo no es la restricción principal.
Menu5: CHILAQUILES DE CACAHUATE	baja 25	Se supone: totopos fritos, altos en carbohidratos de rápida absorción.	Supuesto declarado con «Se supone:»	Falta agregar que la salsa de cacahuate es alta en calorías y grasas.
Menu7: JALAPEÑO CHEDDAR	media 40	Buena proteína y vegetales, pero alta en grasa por el tocino y queso.	Usa grasa, que no es criterio del perfil; puntaje en el umbral (40)	Tomar en cuenta el pan.
Menu9: Café americano	alta 95	Café negro sin azúcar añadido, no eleva la glucosa.	Afirma un efecto fisiológico («no eleva la glucosa»)	En algunos pacientes la cafeína pura en ayunas puede generar un pico de cortisol que altera la glucosa.
Menu9: Naranjada - Mineral	baja 25	Contiene fructosa de la fruta y comúnmente azúcar añadida.	Afirma azúcar añadida sin «Se supone:»	Muchas naranjadas no llevan jugo natural, sino jarabes procesados sabor naranja.

6.6 Consistencia y variabilidad

- **Mismo restaurante, dos fotos (menús 10 y 12), prompt v3:** Se compararon 47 entradas de cada menú, encontrándose 33 platillos emparejados por nombre. De ellos, 30 mantuvieron la misma categoría de compatibilidad y la diferencia media de puntaje fue de 4.7 puntos (máxima de 14 puntos), lo que refleja una alta consistencia entre los resultados obtenidos a partir de distintas fotografías del mismo restaurante.
- **Mismo producto en distintos menús:** la Corona salió «media» con 40 en el Menú 1 y «baja» con 35 en el Menú 3. «Modelo» salió como «Modelo Especial» en el Menú 1 y como «Modelo» en el Menú 3. El sabor «clementina damasco» se separó en dos entradas en el Menú 1 y quedó unido en el Menú 3. Es variabilidad normal del modelo y justifica no ajustar el prompt caso por caso.

7. Hallazgos principales

1. **Lectura fiable.** Con el prompt v3 la precisión es de 99.9 % y la cobertura de 99.8 % en 812 entradas; el modelo prácticamente no inventa entradas.
2. **El prompt pesa mucho.** La cobertura media pasó de 67 % (v1) a casi 100 % (v3). En los menús comparados con el mismo modelo (1 y 14 con 3.8; 6 y 8 con 3.6) la mejora vino del prompt. El Menú 14 es el ejemplo: de 15 a 57 entradas con la misma foto y el mismo modelo.
3. **Hay que pedir explícitamente la expansión de variantes**, con ejemplo; si no, el modelo agrupa.
4. **Hay que dejar al modelo avisar lo que no leyó.** `secciones_no_leidas` funcionó (por ejemplo, la columna cortada del Menú 6).
5. **La categoría de compatibilidad es una etiqueta; el puntaje ordena.** Cerca de los umbrales la categoría cambia con diferencias de 5 puntos entre corridas.
6. **La calificación de compatibilidad es la parte débil:** a veces afirma sin avisar que algo lleva azúcar, usa criterios ajenos al perfil (grasa) o describe efectos sobre la glucosa.
7. **El campo `calidad_imagen` del modelo no es confiable** (calificó «buena» una foto de baja resolución).
8. **El prefijo «Se supone:» se cumple a medias:** aparece en 1 de las 10 razones discrepantes, aunque al menos 4 de ellas daban por hecho algo sobre el azúcar.

8. Incidencias técnicas

Error	Causa	Solución
404 `NOT_FOUND`	`gemini-2.5-flash` ya no está disponible para cuentas nuevas	Listar modelos disponibles con la llave (`listar_modelos.py`) y fijar `GEMINI_MODEL=gemini-3.8-flash`
403 `PERMISSION_DENIED` («project has been denied access»)	Restricción del proyecto de la llave	Llave nueva en un proyecto nuevo de AI Studio
429 por minuto	Nivel gratuito: 5 solicitudes por minuto por modelo (observado en octubre de 2026)	Pausa de 13 s entre fotos y reintentos con espera
429 por día	Nivel gratuito: 20 solicitudes diarias por modelo (observado en octubre de 2026); el aviso pedía esperar más de 2 horas	La cuota es por modelo; esperar al reinicio. El script detecta `PerDay` y se detiene
503 `UNAVAILABLE`	Alta demanda del modelo	Reintentos con espera creciente (15, 30, 60 y 90 s); se resolvió en los reintentos
JSON incompleto (Menú 3)	Límite de 16 000 tokens de salida, rebasado por un menú de unas 150 entradas	32 000 tokens y salida más compacta; el script guarda el texto parcial y el motivo de corte

9. Limitaciones

- 15 menús de restaurantes de Guadalajara, en español, la mayoría con fotos claras o capturas de PDF.
- Un solo perfil de usuario de prueba (diabetes tipo 2) con cuatro criterios.
- Revisión por las propias autoras y una estudiante de medicina; no hay validación clínica formal.
- La compatibilidad se midió en 158 entradas, no en las 812.
- Hay variabilidad entre corridas, y los intervalos de confianza son orientativos.
- Cuota gratuita de 20 solicitudes diarias por modelo: insuficiente para pruebas con varios usuarios a la vez.
- Los menús 10 y 12 son el mismo restaurante, por lo que cuentan como una sola fuente de variedad.

10. Decisiones y trabajo futuro

Decisiones tomadas

1. Mantener Gemini como VLM del módulo de menús, siempre detrás de un servicio del backend para poder cambiar de proveedor.
2. Pedir al modelo `tipo`, `puntaje`, `razon` y `secciones_no_leidas`, y **ordenar por puntaje**, usando la categoría como etiqueta.
3. Mostrar por pestañas Platillos, Bebidas y Postres.
4. Los extras y modificadores no se califican en esta versión.

Mejoras propuestas para la app

1. Criterio opcional «limitar alcohol» en el perfil.
2. Ícono de «estimado» cuando la razón empiece con «Se supone:».
3. Texto de razón centrado en los criterios del perfil, sin afirmar efectos sobre la glucosa (coherente con que la app no da indicaciones médicas).
4. Filtro de nitidez en la app antes de enviar la foto, en lugar de confiar en `calidad_imagen` del modelo.
5. Caché de resultados por restaurante y límite de análisis por usuario por día.
6. Revisión clínica formal de las calificaciones antes de pruebas con usuarios.

Actualizaciones propuestas al Charter

- Riesgo «Baja precisión del VLM»: la probabilidad baja de alta a media, y la mitigación queda como lineamientos de captura y reintento.
- Nuevo riesgo: **límites de uso del nivel gratuito** (20 solicitudes diarias por modelo), con la mitigación de caché, tope por usuario y presupuesto para el nivel de pago en las pruebas de abril.
- Privacidad: antes de enviar datos reales de usuarios al modelo, confirmar en los términos oficiales de Google cómo se trata el contenido enviado en el nivel gratuito frente al de pago, y enviar solo los criterios alimentarios, sin datos personales.

Anexo A. Prompt final (v3)

Copia del `PROMPT` de `spike/spike_menuV3.py`, con el perfil de prueba ya sustituido:

```
Eres un asistente que ayuda a una persona con criterios alimentarios a leer menús de
restaurante.
Analiza la imagen del menú y responde SOLO con JSON válido, sin campos adicionales,
con esta estructura:

{
  "legible": true/false,
  "calidad_imagen": "buena|regular|mala",
  "secciones_no_leidas": ["secciones visibles que no pudiste leer"],
  "platillos": [
    {
      "nombre": "texto tal como aparece, con la variante si aplica",
      "tipo": "platillo|bebida|postre",
      "descripcion": "texto del menú, máximo 10 palabras, o null",
      "precio": "texto o null",
      "compatibilidad": "alta|media|baja",
      "puntaje": 0 a 100,
      "razon": "máximo 15 palabras"
    }
  ]
}

Perfil del usuario: {"tipo_diabetes": "tipo 2", "criterios": ["bajo en carbohidratos
refinados", "evitar bebidas azucaradas", "preferir proteína magra y verduras",
"limitar frituras"]}

Reglas:
- Usa solo lo que está escrito en el menú. No inventes platillos.
- Si tu razón depende de algo que NO está escrito en el menú (por ejemplo, suponer
que algo es frito), empieza la razón con "Se supone:".
- Cuando una línea del menú ofrece varias opciones (separadas por comas, por "o", por
"/" o entre paréntesis: sabores, salsas, rellenos, tipos de proteína, tipos de jugo,
refresco o cerveza), crea UNA entrada por cada opción, con nombre "Producto -
opción". Ejemplo: "Chilaquiles: rojos, verdes o salsa Jalisco" son 3 entradas:
"Chilaquiles - rojos", "Chilaquiles - verdes", "Chilaquiles - salsa Jalisco".
Excepción: si el menú dice que el cliente arma el producto con ingredientes a elegir,
usa una sola entrada.
- Incluye TODAS las secciones visibles. Si una no se puede leer, anótala en
"secciones_no_leidas" en lugar de omitirla.
- Clasifica cada entrada: "bebida" (café, té, jugos, licuados, refrescos, cervezas,
vinos, cocteles), "postre" (postres, pan dulce, galletas, pasteles) y "platillo"
(todo lo demás, incluidas entradas y guarniciones que se piden solas).
- NO incluyas extras ni modificadores: complementos con costo adicional, tamaños,
tipos de leche como cambio de otra bebida, endulzantes, toppings o "agrega X".
- Puntaje: 0 = nada compatible con los criterios, 100 = totalmente compatible. Usa
todo el rango: si dos entradas difieren en algo relevante (tipo de pan, fritura,
carbohidrato refinado, azúcar), sus puntajes deben diferir. "alta" = 70 o más,
"media" = 40 a 69, "baja" = menos de 40.
- No des consejos médicos, no calcules dosis, no diagnostiques.
```

Anexo B. Archivos del spike

Ruta	Contenido
spike/spike_menu.py, spike_menuV2.py, spike_menuV3.py	Versiones del script (prompt v1, v2 y v3)
spike/evaluar.py	Generación de hojas de revisión y cálculo de métricas
spike/results/, results_v2/, results_v3/	JSON de salida del modelo por ronda
spike/evaluacion/, evaluacion_v3/	Hojas de revisión (CSV) y resumen.csv
spike/RESULTADOS.pdf	Bitácora de trabajo del spike
spike/menus/	Fotos de los menús (no versionadas)
docs/decisiones/0002-vlm-congelado.md	Registro de la configuración congelada